

GCN的原始论文，发表于2017年的ICLR会议

解决的问题

如何将神经网络应用在图结构数据上？

问题描述

给定以下输入：

1. 图中顶点的特征矩阵 $H \in \mathbb{R}^{n \times F}$ ，其中 n 为顶点数量， F 为特征数量
2. 图的结构信息，如邻接矩阵 A

输出：

1. 图中顶点新的的特征表示 $H' \in \mathbb{R}^{n \times F'}$ ，即

$$H' = \text{GCN}(H) = g(AHW^T + b)$$

如果套用神经网络模型，每一层可以用一个非线性函数进行表示：

$$H^{(l+1)} = f(H^{(l)}, A)$$

其中 $H^{(0)} = X, H^{(L)} = Z$ ，问题在于如何选取函数 $f(.,.)$

做法及创新

对于函数 $f(.,.)$ 的选取，论文中提出了一种可能的函数形式：

$$f(H^{(l)}, A) = \sigma(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)})$$

其中 $\hat{A} = A + I$ ，因为与矩阵 A 相乘表示对于每个顶点，我们对除了自身外所有邻居顶点的特征向量进行求和，因此加上单位矩阵是为了引入自环。而正则化是避免与矩阵 A 相乘改变特征向量的规模。实际在论文中只使用两层网络就达到了很好的效果，表示为：

$$Z_{\text{GCN}} = \text{softmax}(\hat{A}' \text{ReLU}(\hat{A}' X W_0) W_1)$$

其中 W_0, W_1 为这两层网络的参数， $\hat{A}' = \hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}}$ ， $Z \in \mathbb{R}^{n \times c}$ 为预测的顶点标签， c 为类别数目，毕竟论文解决的就是一个分类问题。

更一般地，使用邻域信息的图神经网络形式可以概括为：

$$h_v^{(l)} = \sigma \left(W_l \cdot \text{AGGREGATE} \left(\{h_u^{(l-1)}, \forall u \in N(v)\} \right) \right)$$

其中 W_l 是第 l 层网络的权重矩阵， AGGREGATE 是与特定模型相关的聚合函数， $h_v^{(l)}$ 是顶点 v 在第 l 层的隐层特征表示。论文中只是用了个两层网络就达到了很好的效果。

将论文所提出的函数改写为上述形式，即为：

$$h_v^{(l)} = \text{ReLU} \left(W_l \cdot \sum_{u \in N(v)} (\deg(v) \deg(u))^{-1/2} h_u^{(l-1)} \right)$$

其中 $\deg(u)$ 为顶点 u 的度。

[AS-GCN](#) 中对这篇论文的模型形式描述如下：

$$h_{v_i}^{(l)} = \sigma\left(W_l \cdot \sum_{j=1}^N a(v_i, u_j) \cdot h_{u_j}^{(l-1)}\right), i = 1, \dots, N$$

这里 $A = (a(v_i, u_j)) \in \mathbb{R}^{N \times N}$ 对应前面一种写法的正则化邻接矩阵 \hat{A}' ，表面上看对于顶点 v_i ，需要考虑将图中剩下的所有顶点的上一时刻的隐层表示做加权和，来作为它当前时刻的隐层表示，因为 j 的取值范围为 $[1, N]$ ， N 就是图中顶点的数量。但实际上，大多数顶点因为与 v_i 并无边相连，所以邻接矩阵中对应的值为 0，意味着在加权和中的权重为 0，相当于加权和时只会考虑有边相连的顶点，这同样是考虑邻域，只不过跟上面那种写法不同。