

解决的问题

如何将GNN应用于社会化推荐任务上。

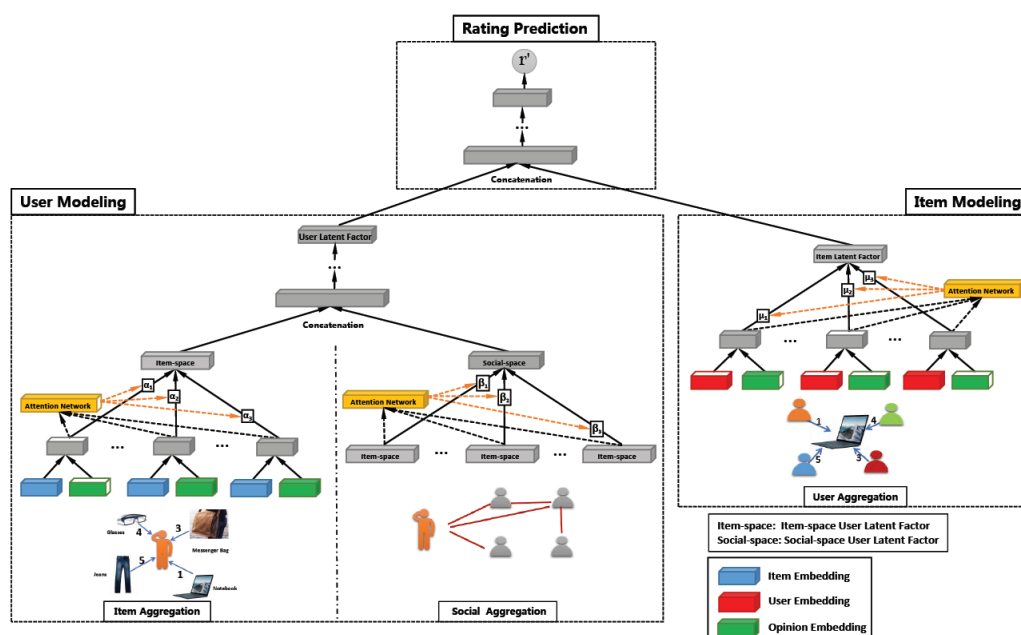
面临的挑战有三点：

1. 在一个社会化推荐任务中，输入的数据包括社会关系图 and 用户-物品交互图，将两张图的信息都聚合才能得到用户更好的一个表示，而此前的GNN只是在同一张图上对邻域内的信息聚合。
2. 在用户-物品交互图中，顶点与顶点之间的边也包含更多的信息，除了表示是否交互，还能表示用户对于一个物品的偏好（喜爱还是厌恶），而此前的GNN只是将边用来表示是否交互。
3. 社会关系图中用户之间的纽带有强有弱，显然地，一个用户更可能与强纽带的其它用户有类似的喜好。如果将所有纽带关系都看成一样，会有偏差。

做法及创新

创新：

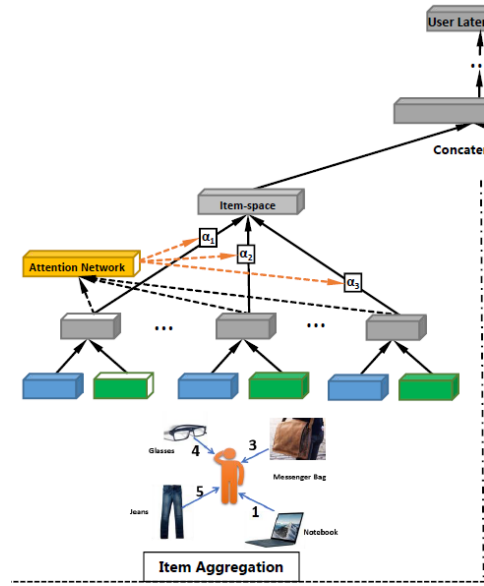
- 在不同图(user-user graph和user-item graph)上进行信息传递与聚合
- 除了捕获user-item间的交互关系，还利用了user对item的评分
- 用attention机制表示社交关系的重要性，用户纽带的强与弱



整个GraphRec框架由三个部分组成，分别为user modeling、item modeling和rating prediction。其中user modeling用来学习用户的特征表示，学习的方式是两个聚合：item aggregation和social aggregation，类似地item modeling用来学习物品的特征表示，学习的方式是一个聚合：user aggregation。

User Modeling

item aggregation



item aggregation的目的是通过用户交互过的物品以及对这些物品的倾向，来学习物品侧的用户特征表示，数学表示为：

$$h_i^I = \sigma(W \cdot Aggre_{items}(\{x_{ia}, \forall a \in C(i)\}) + b)$$

$C(i)$ 就表示用户交互过的物品的一个集合。这里的 x_{ia} 是一个表示向量，它应该能够同时表示交互关系和用户倾向。论文中的做法是通过一个MLP来结合物品的embedding和倾向的embedding，两者分别用 q_a 和 e_r 表示。倾向的embedding可能很难理解，以五分制评分为例，倾向的embedding表示为 $e_r \in \mathbb{R}^d$ ，其中 $r \in \{1, 2, 3, 4, 5\}$ 。

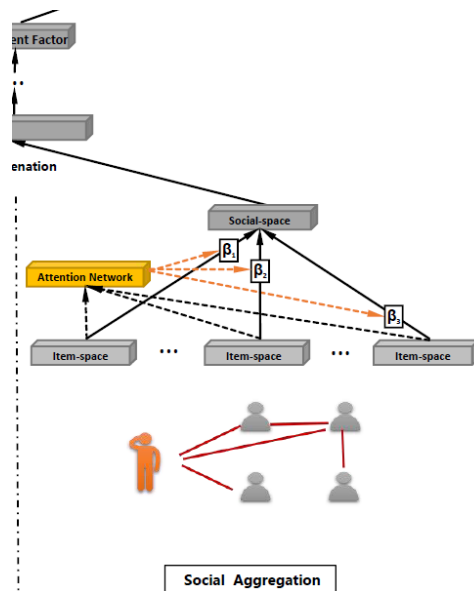
$$x_{ia} = g_v([q_a \oplus e_r])$$

定义好 x_{ia} 后，下一步就是如何选取聚合函数 $Aggre$ 了。论文中使用的是attention机制，来源于[GAT](#)：

$$\begin{aligned} h_i^I &= \sigma(W \cdot \left\{ \sum_{a \in C(i)} \alpha_{ia} x_{ia} \right\} + b) \\ \alpha'_{ia} &= w_2^T \cdot \sigma(W_1 \cdot [x_{ia} \oplus p_i] + b_1) + b_2 \\ \alpha_{ia} &= \frac{\exp(\alpha'_{ia})}{\sum_{a \in C(i)} \exp(\alpha'_{ia})} \end{aligned}$$

这里的权重 α_{ia} 考虑了 x_{ia} 和用户 u_i 的embedding p_i ，使得权重能够与当前用户相关。

social aggregation



social aggregation中，同样地使用了attention机制，通过attention机制来选取强纽带的其它用户（表现为聚合时权重更大）并聚合他们的信息，聚合的就是物品侧的用户特征表示。

$$h_i^S = \sigma(W \cdot \left\{ \sum_{o \in N(i)} \beta_{io} h_o^I \right\} + b)$$

$$\beta'_{io} = w_2^T \cdot \sigma(W_1 \cdot [h_o^I \oplus p_i] + b_1) + b_2$$

$$\beta_{io} = \frac{\exp(\beta'_{io})}{\sum_{o \in N(i)} \exp(\beta'_{io})}$$

这里跟item aggregation基本一模一样，就不多介绍了。

得到物品侧的用户特征表示 h_i^I 和社交侧的用户特征表示 h_i^S 后，用一个MLP将它们结合，得到用户最终的特征表示：

$$c_1 = [h_i^I \oplus h_i^S]$$


$$c_2 = \sigma(W_2 \cdot c_1 + b_2)$$

$$\dots \dots \dots$$

$$h_i = \sigma(W_l \cdot c_{l-1} + b_l)$$

Item Modeling

user aggregation



Item modeling与User modeling的做法基本一模一样...公式都是一一对应的：

$$\begin{aligned}
 f_{jt} &= g_u([p_t \oplus e_r]) \\
 z_j &= \sigma(W \cdot \left\{ \sum_{t \in B(j)} \mu_{jt} f_{jt} \right\} + b) \\
 \mu'_{jt} &= w_2^T \cdot \sigma(W_1 \cdot [f_{jt} \oplus q_j] + b_1) + b_2 \\
 \mu_{jt} &= \frac{\exp(\mu'_{jt})}{\sum_{a \in C(i)} \exp(\mu'_{jt})}
 \end{aligned}$$

Rating Prediction

最后来到评分预测部分，由上面两个部分我们得到了用户特征表示 h_i 与物品特征表示 z_j ，产生评分用的也是一个MLP：

$$\begin{aligned}
 g_1 &= [h_i \oplus z_j] \\
 g_2 &= \sigma(W_2 \cdot g_1 + b_2) \\
 &\dots\dots\dots \\
 g_{l-1} &= \sigma(W_l \cdot g_{l-1} + b_l) \\
 r_{ij} &= w^T \cdot g_{l-1}
 \end{aligned}$$

数据集

Ciao、Epinions