


解决的问题

在协同过滤中，图卷积网络中的特征转换与非线性激活对提升模型表现贡献很小，甚至有负面影响。

在半监督顶点分类问题中，每个顶点有充分的语义特征作为输入，例如一篇文章的标题与摘要词，这种情况下加入多层的非线性特征转换能够有助于学习特征。而在协同过滤任务中，每个顶点（用户或商品）没有这么充分的语义特征，因此没有多大的作用。

做法及创新



$$\hat{y}_{ui} = e_u^T e_i$$

$$e_u = \sum_{k=0}^K \alpha_k e_u^{(k)}$$

$$e_i = \sum_{k=0}^K \alpha_k e_i^{(k)}$$

$$e_u^{(k+1)} = \sum_{i \in N_u} \frac{1}{\sqrt{|N_u| |N_i|}} e_i^{(k)}$$

$$e_i^{(k+1)} = \sum_{u \in N_i} \frac{1}{\sqrt{|N_i| |N_u|}} e_u^{(k)}$$

1. 仅考虑图卷积网络中的neighborhood aggregation，通过在用户-物品交互网络中线性传播来学习用户和物品的embedding，再通过加权和将各层学习的embedding作为最后的embedding
2. 通过减少不必要的架构，相较于NGCF大大减少了需要训练的参数量。唯一需要训练的模型参数是第0层的embedding，即 $e_u^{(0)}$ 与 $e_i^{(0)}$ ，当它们两个给定后，后续层的embedding可以通过传播规则直接进行计算

以加权和的方式结合各层的embedding等价于带自连接的图卷积

$$\begin{aligned} E^{(K)} &= (A + I)E^{(K-1)} = (A + I)^K E^{(0)} \\ &= C_K^0 E^{(0)} + C_K^1 A E^{(0)} + C_K^2 A^2 E^{(0)} + \dots + C_K^K A^K E^{(0)} \end{aligned}$$

3. 模型的可解释性更强，以二层网络为例：

$$e_u^{(2)} = \sum_{i \in N_u} \frac{1}{\sqrt{|N_u||N_i|}} e_i^{(1)} = \sum_{i \in N_u} \frac{1}{|N_i|} \sum_{v \in N_i} \frac{1}{\sqrt{|N_u||N_v|}} e_v^{(0)}$$

如果另一个用户 v 与目标用户 u 有关联，则影响以下面的系数表示：

$$c_{v \rightarrow u} = \frac{1}{\sqrt{|N_u||N_v|}} \sum_{i \in N_u \cap N_v} \frac{1}{|N_i|}$$

可解释为：

- 共同交互过的物品越多系数越大 $i \in N_u \cap N_v$
- 物品流行度越低系数越大 $\frac{1}{|N_i|}$
- 用户 v 越不活跃系数越大 $\frac{1}{|N_v|}$

数据集

Gowalla、Yelp2018、Amazon-Book